中国科学技术大学 University of Science and Technology of China

滕子涵

130-5312-7388 zihant@mail.ustc.edu.cn 合肥市

个人概述

聚焦大模型推理系统加速，具备算法设计、系统优化与底层 GPU 算子研发的跨层技术经验。算法层面研究长上下文 KV Cache 压缩与低比特量化；系统层面参与腾讯万卡级数据生产场景的推理框架优化与流水线加速；算子层面开展高性能 CUDA Attention 后端研发。第一作者论文 SlimKV 获 EMNLP 2026 主会 Oral 录用。

教育经历

中国科学技术大学 2024.09 - 2027.06

微电子学院 电子科学与技术 硕士

- 排名 2/23，GPA 3.91/4.3；新加坡南洋理工大学访问学生（2025.08 - 2026.06）；研究生学业奖学金（一二等各一次）、芯旺奖学金。

中国科学技术大学 2020.09 - 2024.06

物理学院 微电子学与固体电子学 本科

- 排名 8/39，GPA 3.58/4.3；台湾清华大学交换生（2023.07 - 2023.08）；优秀学生奖学金（铜奖两次）、中广核奖学金。

实习经历

腾讯科技（北京）有限公司 2026.06 - 至今

TEG-数据计算平台部 AI Infra实习生（青云计划）

- 高性能 Attention 后端研发： 面向 vLLM 长上下文推理，基于 FlashAttention-3/CUTLASS 将 Per-Token-Head FP8 Attention 从 Triton 迁移至 CUDA 后端，实现细粒度量化与原生 FP8 计算。针对 Paged-KV 中独立 Scale 的访存开销，通过分页寻址去重、Warp 协作加载与 Scale 预取流水化优化，使 Kernel 耗时降低 47%、Global Load 指令减少 88.8%；结合 K 中心化、QK Equalization 等策略降低量化误差，长上下文 Prefill Attention 相较 BF16 加速 1.85×。此外，开发了 PoPE 新型位置编码的高性能 FA3 后端，通过三角函数查表与矩阵乘融合优化计算路径。相关后端已集成至团队仓库并落地实际万卡级别生产业务，计划整理论文投递至MLSys27。
- 多模态推理性能优化： 面向音频、视频及长上下文数据生产业务，利用 Nsight Systems/Compute 定位算子执行、显存访存及调度瓶颈，通过算子重构与融合、Pipeline 并行、Multi-Worker 调度、动态 Batch 优化及 FP8 KV Cache 等手段提升推理吞吐与 GPU 利用率。Text-to-Sound 端到端累计吞吐提升 9.46×，Audio-in-Video 吞吐提升 16.5%，并完成多项业务的推理框架适配与性能优化。
- AI 自动化精度排查工具： 设计跨 PyTorch、vLLM、Torch Compile 的精度排查 AI Skill，实现跨架构语义对齐、Tensor 级差异分析与 Kernel 根因定位，在 Qwen3-VL 等多个真实业务中验证，将周级人工排查缩短至小时级自动化闭环，大大提升团队效率。

上海孚典智能科技有限公司 2024.06 - 2024.08

研发部 机器学习算法实习生

机场视觉算法研发： 面向机场机坪的大尺度视觉标定与动态碰撞预警，设计融合全局参数与多项式曲面拟合的两阶段标定算法，将远场定位精度提升至 0.1 m 级、标定耗时缩短至 1 – 3 分钟；集成 YOLO 实时目标检测，误差控制在 10% 以内，支撑碰撞预警系统落地。

研究经历

SlimKV：联合词元-特征KV缓存压缩框架（EMNLP26 主会 Oral，第一作者） 2026.03 - 2026.06

- 联合 Token-Feature 压缩架构： 提出与查询无关的双维 KV Cache 压缩框架，通过 Beacon Token 汇聚长上下文信息，结合低秩约束训练、SVD 初始化及逐层自适应秩分配，同时压缩缓存 Token 数量与特征维度，缓解高压缩率下的信息损失。
- 免重建潜空间 Attention： 发现 Beacon 与原始 Token 对 Key 侧 RoPE 的依赖存在显著非对称性，仅移除 Beacon K-RoPE，并通过约束训练保留隐式位置信息。利用矩阵乘法结合律将注意力计算转移至低维潜空间，避免全维KV重建，消除长上下文解码的重建开销。
- 实验结果： 在 Llama-3.1-8B、Qwen2.5-14B 上验证，LongBench 16× – 32× 压缩下优于现有基线，4× – 8× 压缩下保留全精度模型 96% 以上的性能。128K 上下文下实现 7.34× Attention 加速、3.38× 端到端解码加速。
- 论文链接：https://arxiv.org/abs/2610.02953。

KV Cache 压缩与大模型推理加速研究 2025.06 - 2025.10

- 跨层低秩 KV 压缩： 针对长上下文 KV Cache 显存瓶颈，提出基于跨层 SVD 的隐状态压缩架构，通过低秩截断去除冗余特征，以降维隐状态替代原始 KV 缓存。在 Llama-3.1-8B 上实现 4× KV Cache 压缩，输出隐状态余弦相似度 0.99，LongBench 仅下降 0.13 分。
- SVD 预计算加速： 针对 Prefill 阶段跨层 SVD 的额外计算开销，利用 CKA 分析验证特征子空间的跨输入稳定性，设计“离线预计算U + 在线映射V”的加速方案，在 64K 上下文下将单层 SVD 耗时从 19s 降至 1.5s（12.67×），压缩耗时占 Prefill 总时长的 30% 以内。

混合专家模型低比特量化研究（ICLR27在投，第二作者） 2025.08 - 2026.01

- 细粒度 MoE 量化算法优化： 针对传统专家级量化难以刻画内部敏感度差异的问题，参与 BitsMoE 算法研究。基于跨专家共享谱基底分解（SSD），将专家权重拆分为细粒度谱分量；结合谱重要性、激活敏感度与量化失真构建代价模型（FQCM），通过全局整数线性规划（ILP）实现显存预算约束下的自适应位宽分配，并参与 ILP 目标函数修正与跨层位宽分配策略优化。
- 实验复现与性能评估： 负责 MoEQuant 等基线复现、跨模型低比特量化实验及结果分析。在 Qwen3-30B-A3B 2-bit 设置下，7 项任务平均准确率达 64.29%，较 MoEQuant、GEMQ 分别提升 5.96、2.80 个百分点，离线量化速度较 GEMQ 提升 16.47×。
- 论文链接： https://arxiv.org/abs/2606.00079。

技能

- **编程与工具:** Python， Linux， Git， C， Shell， LaTeX
- **深度学习:** Transformers， CUDA， LoRA， PyTorch， vLLM， Flash Attention， Nsight System， Nsight Compute
- **大模型:** 长上下文推理优化， 混合专家模型量化， KVCache 压缩， 提示词压缩， AI Agent， 算子优化
- **英语:** CET-6，能够使用英语进行论文阅读、研究汇报与基本学术交流