中国科学技术大学 University of Science and Technology of China

滕子涵

130-5312-7388 zihant@mail.ustc.edu.cn 合肥市

个人概述

聚焦大语言模型长上下文建模与推理优化，具备 AI Infra 工程实践经验，参与万卡级大模型训练数据生产部署，掌握大模型微调、基于 vLLM 的推理优化、训练/推理流水线搭建、算子优化与性能分析。研究方向包括 KV Cache 压缩、提示词软压缩及混合专家模型量化。

教育经历

中国科学技术大学 2024.09 - 2027.06

微电子学院 电子科学与技术 硕士

- 排名 2/23，GPA 3.91/4.3；新加坡南洋理工大学访问学生（2025.08 - 2026.06）；研究生学业奖学金（一二等各一次）、芯旺奖学金。

中国科学技术大学 2020.09 - 2024.06

物理学院 微电子学与固体电子学 本科

- 排名 8/39，GPA 3.58/4.3；台湾清华大学交换生（2023.07 - 2023.08）；优秀学生奖学金（铜奖两次）、中广核奖学金。

研究经历

SlimKV：联合词元-特征KV缓存压缩框架（EMNLP26主会，第一作者） 2026.03 - 2026.06

- 联合token-特征压缩架构设计：
  - 挑战：token级压缩易丢信息，特征级低秩压缩又需在解码时重构全维度Key，限制加速效果。
  - 方法：训练beacon token的低秩KV投影，联合token与特征双维度压缩，并按层低秩谱结构自适应分配秩预算。
  - 结果：LongBench上16x – 32x高压缩比下性能超越ActivationBeacon等基线，4x-8x压缩率较未压缩模型保留96%以上分数。
- 无需重建的隐空间注意力计算：
  - 挑战：低秩Key需先重构为全维度才能应用RoPE位置编码并计算注意力，重构开销随缓存长度线性增长，限制解码加速上限。
  - 方法：发现beacon与原始token对Key侧RoPE依赖的非对称性，仅移除beacon Key的RoPE，使注意力可直接在隐空间完成。
  - 结果：128K上下文下实现最高7.34倍注意力计算加速、3.38倍端到端解码加速，峰值显存降低约2.7倍。

KV Cache 压缩与大模型推理加速研究 2025.06 - 2025.10

- 显存压缩：
  - 挑战： 长上下文推理显存占用高，传统 KV Cache 驱逐/量化存在精度或结构限制。
  - 方法： 提出基于隐藏层状态的跨层 SVD 降维架构，通过低秩截断去除冗余特征，存储降维后状态以替代原始缓存。
  - 结果： Llama-3.1-8B 上实现 4 倍 KV Cache 压缩，输出层隐藏状态达到 0.99 余弦相似度，LongBench 39.82，较全精度下降 0.13。
- 推理加速：
  - 挑战： 跨层 SVD 在 Prefill 阶段引入额外计算延迟。
  - 方法： 基于 CKA 验证特征基空间 U 的输入无关性，设计“离线预计算 U + 在线映射 V”的 SVD 加速方案。
  - 结果： 在 64K 上下文下将单组 SVD 时间由 19s 降至 1.5s，实现 12.67 倍提速，压缩耗时占 Prefill 总时长 30% 以内。

混合专家模型低比特量化研究（ICLR27在投，第二作者） 2025.08 - 2026.01

- 参与算法关键细节修正。 针对 MoE 大模型部署中显存开销大、低比特量化精度退化明显的问题，该工作研究了基于共享基底低秩分解与自适应比特分配的优化方案，并将低比特 MoE 的量化预算分配建模为 ILP 问题；本人参与算法推导细节修正，修正了 ILP 最小化目标函数中的一处关键细节。在 Qwen3-30B-A3B 2-bit 设置下，平均准确率达到 66.94%，较 FP16 仅下降 3.92%，较 MoEQuant 提升 4.52%，并实现 6.32 倍显存压缩。
- 协同提出自适应层间位宽分配策略。 基于层间量化敏感性建模，综合考虑层内权重重要性与跨层敏感性差异，实现更细粒度、动态的量化预算分配机制。
- 负责高难度基线的复现与实验评测。 完成 MoEQuant 关键基线的复现与多种主流 MoE Backbone 低比特设置下的实验验证，独立负责结果对比、数据可视化与分析，并协同推进论文撰写。论文链接：https://arxiv.org/pdf/2606.00079。

实习经历

腾讯科技（北京）有限公司 2026.06 - 至今

TEG-数据计算平台部 AI Infra实习生（青云计划）

负责数据管道算子优化与自动化工具建设，支撑混元等大模型训练数据的万卡级离线生产，处于模型训练全链路上游。通过算子重构、融合及并行化优化关键计算算子，并参与 vLLM 推理框架二次开发与自定义高性能 Kernel 集成，提升模型推理吞吐，部分算子实现近 10 倍性能提升，累计节省数十万 GPU 卡时部署成本。同时主导团队自动化工具整合，将常用能力沉淀为可复用工具，提升研发效率。

上海孚典智能科技有限公司 2024.06 - 2024.08

研发部 机器学习算法实习生

面向机场机坪的大尺度视觉标定与动态碰撞预警系统，解决超大场景空间标定精度与实时安全监测两大核心问题。针对复杂畸变难题设计两阶段标定策略（遗传算法求解全局参数+多项式曲面拟合残差补偿），并基于PyQt5封装为可视化标定软件，将近场定位精度提升至0.1m级，标定耗时压缩至1-3分钟；集成YOLO算法实现跨帧测速，误差控制在10%以内，支持碰撞预警。

技能

- **编程与工具:** Python， Linux， Git， C， Shell， LaTeX
- **深度学习:** Transformers， CUDA， LoRA， PyTorch， vLLM， Flash Attention
- **大模型:** 长上下文推理优化， 混合专家模型量化， KVCache 压缩， 提示词压缩， AI Agent， 算子优化
- **英语:** CET-6，能够使用英语进行论文阅读、研究汇报与基本学术交流